Máquinas de Soporte Vectorial (SVM)

Predicción de demanda y explicabilidad (XAI)

Michael Lata · Técnicas de ML Supervisado

Informe teórico + Notebook de modelado + Notebook de XAI

SVM y vectores de soporte

Idea: hallar el hiperplano que MAXIMIZA EL MARGEN entre clases.

Vectores de soporte = los únicos puntos que definen el hiperplano; el resto no influye.

Proceso interno (condiciones KKT) — clasifica cada punto por su α_i:

- $\alpha_i = 0 \rightarrow$ no es vector de soporte
- $0 < \alpha_i < C \rightarrow$ vector de soporte libre (fija b)
- $\alpha_i = C \rightarrow$ vector de soporte acotado (dentro/viola el margen)

Decisión: $f(x) = \text{sign}(\Sigma_SV\ \alpha_i\ y_i\ K(x_i,x) + b)$ — suma SOLO sobre vectores de soporte.

Kernel trick: proyecta a más dimensiones para separar lo no lineal (RBF por defecto).

SVR: misma idea para regresión, ajustando dentro de un tubo de ancho ε.

Aplicación: predicción de demanda (SVM/SVR)

Dataset de la Práctica 2: histórico de ventas de 10 productos (~180 días c/u).

Mismas 12 features que la práctica: lags, medias móviles, calendario, stock, categoría.

Pipeline robusto: StandardScaler + SVR(RBF) · GridSearchCV · split temporal (sin fuga).

Resultado: el SVR SUPERA al modelo de la práctica (LSTM/boosting):

R^2 0.42 vs 0.28 · RMSE 5.1 vs 7.1 · MAE 3.6 vs 5.2

Caso de negocio extra (SVC): alerta de días de alta demanda (ROC-AUC 0.70).

Ventaja para la empresa: determinista, entrena en segundos, sin GPU, fácil de mantener.

XAI: explicando el modelo de demanda

Problema: el SVR-RBF es una caja negra → una empresa necesita entender por qué predice.

Tres técnicas complementarias:

- Importancia por permutación → ranking de factores de la demanda.
- PDP → forma con que cada factor afecta la demanda.
- SHAP → atribución global (beeswarm) y LOCAL por día (waterfall).

Factores que mandan: media móvil 7d, día de la semana, fin de semana, proporción de stock.

Valor: anticipar reposiciones y JUSTIFICAR cada alerta → confianza y trazabilidad.

Los tres métodos coinciden en los factores top → da confianza en la interpretación.

Conclusiones

Teoría → práctica: implementamos toda la cadena SVM y verificamos numéricamente el proceso interno (reconstrucción de w, b y f(x) solo desde vectores de soporte).

Sobre el dataset de la Práctica 2, SVR IGUALA Y SUPERA a modelos más complejos (LSTM/boosting).

Más atractiva para empresas: determinista, ligera, sin GPU, robusta con pocos datos y EXPLICABLE.

XAI (permutación + PDP + SHAP) convierte la caja negra en decisiones auditables de negocio.

Entregables: informe (PDF), 3 notebooks ejecutados y esta presentación — todo reproducible.

Trabajo futuro: más productos/SKUs, horizonte semanal, variables de promociones y precio.