¿Cómo pronosticamos la demanda? — 4 pasos

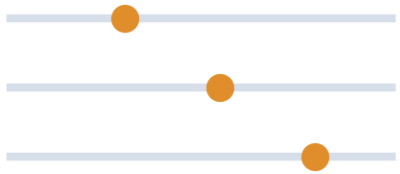
Del historial de ventas a la decisión de cuánto reabastecer

1 Historial de ventas



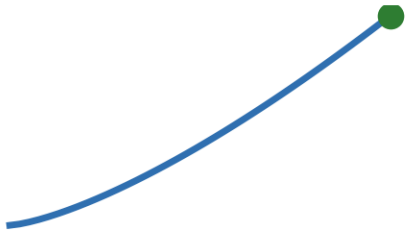
Tomamos las ventas recientes de cada producto.

2 Señales clave



Las resumimos en pistas: promedio de la semana, día, fin de semana, stock.

3 La SVM pronostica



El modelo predice la demanda de mañana, producto por producto.

4 Decisión de inventario



Traducimos el pronóstico en cuánto reabastecer: sin quebrar ni sobrar.

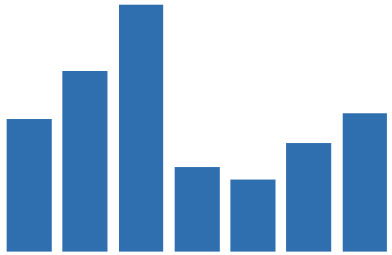
Un proceso simple, automático y explicable — el mismo para los 10 productos

Ejemplo real: Cable USB-C — pronóstico para el sábado

Siguiendo los mismos 4 pasos con datos reales (2026-09-05)

1 Historial de ventas

últimos 7 días



Ventas diarias reales
(promedio ≈ 23/día)

2 Señales clave

- Promedio: **23/día**
- Ventas hoy: **23**
- Mañana: **sábado**
- Fin de semana: **sí**

3 La SVM pronostica

≈ 24

unidades mañana

real: 23 ✓

4 Decisión de inventario

Stock actual: 182

Demanda prevista cubierta ✓

Reforzar de cara al
fin de semana por la
alta variabilidad

El modelo predijo 24 y se vendieron 23 → decisión de inventario confiable

Detalle técnico — para el equipo de ingeniería

Modelo SVM · importancia desde su estructura interna · agrupamiento con k-means

1 · Modelo SVM + validación

```
Pipeline([
  StandardScaler(),
  SVR(kernel='rbf', C=10,
      gamma=0.05,
      epsilon=1.0)])

GridSearchCV(
  cv=TimeSeriesSplit(5),
  scoring='neg_RMSE')
```

Resultados:

Vectores de soporte	**1086 / 1380**
RMSE / MAE	**5.11 / 3.65**
R² (vs Práctica 2)	**0.42 vs 0.28**

Validación temporal sin fuga de datos (expanding window).

2 · Importancia de variables

Desde la estructura interna (SVM lineal):

```
w = LinearSVR().coef_   # peso/feature
|w| ordenado  -> importancia
```

|w| rolling_mean_7	**4.66**
|w| cantidad_vendida	**1.11**
|w| lag_1	**0.61**
|w| es_weekend	**0.55**

rolling_mean_7 pesa más que las otras 11 juntas (4.66 > 4.52).

Validado (model-agnostic):

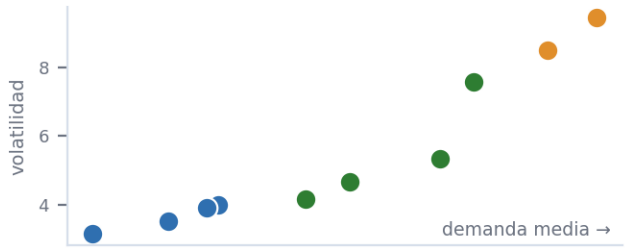
permutation · SHAP · Integrated Gradients → Top-3 coincide

RBF no expone w → para el modelo final se usa SHAP/perm.

3 · Productos similares (k-means)

```
perfil_producto = [
  demanda_media, volatilidad,
  uplift_finde, stock_medio]

KMeans(n_clusters=3, n_init=10)
   .fit(scale(perfil))
```



3 grupos: G0 estables (4) ·

G1 volumen medio (4) ·

G2 alta rotación / finde (2)

Stack: scikit-learn · StandardScaler · SVR / LinearSVR · KMeans · SHAP — determinista y sin GPU